

A. Manual de Usuario

El presente manual constituye una guía operativa destinada a orientar al usuario en la instalación, puesta en marcha y utilización de la prueba de concepto NYC Crime SDM Dashboard. La inclusión de este manual responde al objetivo metodológico de facilitar la transferencia del sistema y la repetición de los análisis en futuras investigaciones. El público objetivo incluye investigadores criminalísticos, analistas de datos y auditores metodológicos que requieran interactuar empíricamente con la herramienta. A diferencia de los capítulos 4 y 5, que documentan las decisiones de diseño e implementación interna, este manual se enfoca exclusivamente en la perspectiva del usuario final.

El manual se organiza de la siguiente manera: la Sección A.1 detalla los requisitos del sistema y el procedimiento de instalación; la Sección A.2 presenta la estructura general de la interfaz, el sistema de filtros globales y el manejo de recursos computacionales; la Sección A.3 describe la operación del módulo de estadísticas descriptivas; la Sección A.4 aborda el módulo de análisis avanzado; y la Sección A.5 ofrece una guía para la correcta interpretación de los resultados.

A.1. Requisitos Previos e Instalación

Para favorecer la reproducibilidad del entorno analítico, la prueba de concepto fue empaquetada íntegramente en contenedores lógicos aislados. Esto implica que el usuario no necesita instalar intérpretes de lenguajes de programación, bibliotecas de análisis de datos ni dependencias auxiliares de manera individual en su sistema operativo. El único software que debe instalarse es la plataforma de contenerización, aunque el equipo debe cumplir además los requisitos de memoria que se detallan en la sección A.1.1. Los contenedores no garantizan, por sí solos, un entorno idéntico en cada instalación, dado que las bibliotecas se instalan a partir de versiones mínimas al construir la imagen.

A.1.1. Requisitos del Sistema

En la Tabla 6 se detallan los requisitos mínimos y recomendados para la ejecución del sistema.

Componente	Requisito	Observaciones
Plataforma de contene-rización	Docker 20.10+ con Docker Compose V2	Disponible para Windows, macOS y Linux. Incluye la orquestación de servicios necesaria para coordinar el pipeline y el dashboard.
Memoria RAM	16 GB mínimo (32 GB recomendado)	El pipeline ETL procesa masiva-mente registros en memoria e instan-cias de machine learning. En Win-dows y macOS con Docker Desk-top, es indispensable asignar ma-nualmente al menos 16 GB a la má-quina virtual (<i>Settings >Resources</i> o archivo <i>.wslconfig</i>), dado que por defecto Docker asigna única-mente el 50 % de la memoria del sis-tema anfitrión.
Espacio en disco	3 GB libres	Contempla la imagen de los conte-nedores (~1,6 GB), compartida por los tres servicios, y los datos descar-gados y procesados en formato Par-quet (~200 MB).
Conexión a internet	Solo durante la ex-tracción	Requerida únicamente para la des-carga inicial de datos desde las APIs públicas. Una vez ejecutado el pipe-line, el dashboard opera en modo lo-cal sin conectividad.

Tabla 6: Requisitos del sistema para la ejecución de la prueba de concepto.

A.1.2. Procedimiento de Instalación

El despliegue del sistema se realiza en tres pasos secuenciales. En primer lugar, se obtiene el repositorio del proyecto. Seguidamente, se ejecuta el *pipeline* de extracción y transformación de datos. Finalmente, se inicia el servidor del *dashboard* interactivo.

Paso 1: Obtención del repositorio. El código fuente del proyecto se distribuye mediante un sistema de control de versiones. El usuario debe clonar el repositorio en su equipo local mediante el comando correspondiente de la herramienta Git:

```
git clone https://github.com/NicoCapellino/Tesis-Repo.git
cd Tesis-Repo
```

Paso 2: Ejecución del pipeline ETL. Este proceso descarga los datos crudos desde las fuentes primarias los *datasets* oficiales de denuncias del NYPD desde NYC Open Data, las capas de equipamiento institucional desde el servicio WFS del USGS National Map y las paradas de ómnibus desde el portal de datos abiertos del estado de Nueva York, los transforma, valida su consistencia geoespacial y los almacena en formato optimizado Parquet. Se ejecuta una única vez o cuando se desee actualizar el corpus de datos:

```
docker compose run --rm pipeline
```

La ejecución puede demorar entre cinco y veinte minutos según la velocidad de la conexión a internet, dado que descarga y procesa un volumen masivo de registros históricos. Al finalizar, el sistema informa el tiempo total de ejecución y la ubicación de los artefactos generados, como se ilustra en la Ilustración 17.

En caso de que ya se disponga de los datos descargados y solo se requiera re-ejecutar la fase de transformación (sin volver a descargar), se puede emplear la opción correspondiente:

```
docker compose run --rm pipeline \
python -m src.pipeline --skip-extract
```

```

2026-09-23T01:04:06.0765902 [info] phase_extract_complaints_done [__main__] path=/app/data/raw/complaints
2026-09-23T01:04:06.0795952 [info] usgs_fetch_start [src.extract.usgs_structures] city=new_york filetype=800
2026-09-23T01:04:06.0797952 [info] usgs_ufs_request [src.extract.usgs_structures] filetype=800 url=https://carto-wfs.nationalmap.gov/arcgis/services/structures/MapServer/NFSServer
2026-09-23T01:04:07.7039782 [info] usgs_ufs_response [src.extract.usgs_structures] matched=237 returned=237
2026-09-23T01:04:07.7303282 [info] usgs_nyc_filter [src.extract.usgs_structures] dropped=162 kept=75
2026-09-23T01:04:07.7313302 [info] usgs_fetch_done [src.extract.usgs_structures] filetype=800 records=75
2026-09-23T01:04:07.7438112 [info] saved_healthcare [src.extract.usgs_structures] path=/app/data/reference/new_york/healthcare.parquet records=75
2026-09-23T01:04:07.7439552 [info] usgs_fetch_start [src.extract.usgs_structures] city=new_york filetype=760
2026-09-23T01:04:07.7440542 [info] usgs_ufs_request [src.extract.usgs_structures] filetype=760 url=https://carto-wfs.nationalmap.gov/arcgis/services/structures/MapServer/NFSServer
2026-09-23T01:04:11.4822412 [info] usgs_ufs_response [src.extract.usgs_structures] matched=3426 returned=3426
2026-09-23T01:04:11.8888842 [info] usgs_nyc_filter [src.extract.usgs_structures] dropped=3111 kept=315
2026-09-23T01:04:11.9087082 [info] saved_usgs_police [src.extract.usgs_structures] path=/app/data/reference/new_york/usgs_police.parquet records=95
2026-09-23T01:04:11.9160502 [info] saved_usgs_fire [src.extract.usgs_structures] path=/app/data/reference/new_york/usgs_fire.parquet records=220
2026-09-23T01:04:11.9163642 [info] phase_extract_usgs_done [__main__]
2026-09-23T01:04:11.9187232 [info] mta_fetch_start [src.extract.mta_bus_stops] city=new_york
2026-09-23T01:04:11.9243372 [info] mta_response [src.extract.mta_bus_stops] returned=13610
2026-09-23T01:04:13.8137412 [info] mta_fetch_done [src.extract.mta_bus_stops] city=new_york records=13610
2026-09-23T01:04:13.8246012 [info] saved_mta_bus_stops [src.extract.mta_bus_stops] path=/app/data/reference/new_york/mta_bus_stops.parquet records=13610
2026-09-23T01:04:13.8258952 [info] phase_extract_mta_done [__main__]
2026-09-23T01:04:13.8252122 [info] phase_transform_start [__main__]
2026-09-23T01:04:13.8408972 [info] reading_raw_files [src.transform.complaints] count=0
2026-09-23T01:04:14.3831532 [info] transform_start [src.transform.complaints] input_cols=36 input_rows=3098259
2026-09-23T01:04:14.5748442 [info] transform_complete [src.transform.complaints] output_cols=28 output_rows=3098259
2026-09-23T01:04:14.7145522 [info] saved_processed_year [src.transform.complaints] records=414188 year=2020
2026-09-23T01:04:14.8708122 [info] saved_processed_year [src.transform.complaints] records=450325 year=2021
2026-09-23T01:04:15.0463432 [info] saved_processed_year [src.transform.complaints] records=531250 year=2022
2026-09-23T01:04:15.2227902 [info] saved_processed_year [src.transform.complaints] records=53693 year=2023
2026-09-23T01:04:15.4100882 [info] saved_processed_year [src.transform.complaints] records=574239 year=2024
2026-09-23T01:04:15.5989472 [info] saved_processed_year [src.transform.complaints] records=574564 year=2025
2026-09-23T01:04:15.6885262 [info] coordinates_filtered [src.transform.geospatial] pct_removed=0.0 remaining=414187 removed=1
2026-09-23T01:04:15.8885592 [info] coordinates_filtered [src.transform.geospatial] pct_removed=0.0 remaining=450324 removed=1
2026-09-23T01:04:16.1831632 [info] coordinates_filtered [src.transform.geospatial] pct_removed=0.0 remaining=531247 removed=3
2026-09-23T01:04:16.4535802 [info] coordinates_filtered [src.transform.geospatial] pct_removed=0.0 remaining=53686 removed=13
2026-09-23T01:04:16.7211532 [info] coordinates_filtered [src.transform.geospatial] pct_removed=0.0 remaining=574212 removed=27
2026-09-23T01:04:17.1880692 [info] phase_transform_done [__main__] invalid_coordinates_removed=45 valid_records=3098214
2026-09-23T01:04:17.1883452 [info] pipeline_complete [__main__] elapsed_seconds=724.2 outputs='raw_complaints': /app/data/raw/complaints, 'reference_healthcare': /app/data/referenc
healthcare.parquet, 'reference_usgs_police': /app/data/reference/new_york/usgs_police.parquet, 'reference_usgs_fire': /app/data/reference/new_york/usgs_fire.parquet, 'reference_mta_b
us_stops': /app/data/reference/new_york/mta_bus_stops.parquet, 'processed_complaints': /app/data/processed/complaints'

```

Ilustración 17: Ejecución del pipeline ETL con el resumen de artefactos generados.

Paso 3: Inicio del dashboard. Una vez completado el *pipeline*, se levanta el servidor web del *dashboard*:

```
docker compose up dashboard
```

El sistema queda accesible en el navegador en la dirección `http://localhost:8501`. Para ejecutar el servidor en segundo plano sin ocupar la terminal, se agrega la bandera `-d`:

```
docker compose up -d dashboard
```

A.1.3. Resolución de Problemas Comunes (Troubleshooting)

Durante el proceso de despliegue, pueden surgir algunos inconvenientes vinculados al entorno local del usuario. A continuación se detallan soluciones a los problemas más frecuentes:

- **Puerto 8501 ocupado:** Si el contenedor del *dashboard* falla al iniciar indicando que el puerto ya está en uso, el usuario puede modificar el archivo `docker-compose.yml` cambiando la regla de mapeo de puertos (por ejemplo, a `8502:8501`).

- **Fallo en la descarga de datos (ETL):** Si por cortes de internet o tiempos de espera agotados en la API del NYPD el proceso ETL se interrumpe, los archivos parciales pueden corromper ejecuciones futuras. Dado que el directorio `./data` se monta desde el sistema anfitrión, eliminar los volúmenes de Docker no lo afecta: se recomienda borrar manualmente el subdirectorio afectado dentro de `./data` y volver a ejecutar el Paso 2.
- **Falta de memoria RAM en Docker:** Si el *pipeline* se detiene abruptamente (Killed o OOMKilled), verifique los recursos asignados a la máquina virtual de Docker. En Windows y macOS, Docker Desktop asigna por defecto sólo el 50 % de la memoria física del host. Debe incrementarse manualmente a 16 GB desde *Settings >Resources >Memory* (o en `%USERPROFILE\.wslconfig` bajo `[wsl2] memory=16GB`).
- **Fallas silenciosas:** Si un proceso se interrumpe sin mostrar errores evidentes en la web, se recomienda revisar los registros internos de los contenedores ejecutando el comando `docker compose logs pipeline` o `docker compose logs dashboard`.
- **Permisos en entornos Linux:** En algunas distribuciones de Linux, si el usuario local no pertenece al grupo `docker`, será necesario anteponer `sudo` a todas las instrucciones (e.g., `sudo docker compose up dashboard`).

A.2. Interfaz General del Dashboard

Al acceder al *dashboard* mediante el navegador web, el usuario se encuentra con una interfaz organizada en dos componentes principales: una barra de navegación lateral que permite seleccionar el módulo analítico deseado, y un área de contenido principal donde se despliegan las visualizaciones y resultados correspondientes al módulo activo.

A.2.1. Estructura de Navegación

La barra lateral izquierda organiza las diez vistas analíticas del sistema en dos secciones temáticas, como se observa en la Ilustración 18:

- **Estadísticas Descriptivas:** agrupa las vistas de análisis exploratorio basadas en distribu-

ciones y conteos — Resumen General, Temporal, Geoespacial y Demográfico.

- **Análisis Avanzado:** agrupa las vistas que emplean técnicas de *Spatial Data Mining* — Comparativo, Proximidad, *Clustering K-Means*, Reglas de Asociación, Predicción ML y Anomalías.

Cinco de estas vistas aparecen en la barra lateral con el sufijo V2: Geoespacial V2, Comparativo V2, Proximidad V2, Reglas V2 y Predicción ML V2. El sufijo identifica a las vistas que operan sobre las capas de equipamiento institucional del USGS National Map, incorporadas en la segunda versión de la prueba de concepto. Las cinco restantes no lo llevan porque no utilizan esas capas.




Ilustración 18: Estructura de navegación del dashboard con las secciones y módulos analíticos disponibles.

A.2.2. Sistema de Filtros Globales

Debajo de la barra de navegación, la interfaz presenta tres filtros globales que afectan simultáneamente a **todas** las vistas del sistema. Esta característica resulta fundamental para la exploración analítica, ya que permite al investigador definir un subconjunto de datos y mantenerlo invariante al navegar entre los distintos módulos.

Los filtros disponibles (véase la Ilustración 19) son:

- **Año(s)**: permite seleccionar uno o más años del período 2020–2025. Por defecto, todos los años se encuentran seleccionados.
- **Borough(s)**: permite seleccionar uno o más de los cinco distritos de Nueva York (Manhattan, Brooklyn, Queens, Bronx, Staten Island). Por defecto, todos se encuentran activos.
- **Nivel de ofensa**: permite filtrar por la gravedad del delito según la clasificación legal del NYPD (*Felony*, *Misdemeanor*, *Violation*). Por defecto, los tres niveles se encuentran seleccionados.




Ilustración 19: Filtros globales del dashboard. Los cambios se propagan a todas las vistas de forma inmediata.

Al modificar cualquiera de estos filtros, el subconjunto de datos activo se recalcula de forma inmediata y todas las visualizaciones se actualizan automáticamente para reflejar el nuevo recorte.

A.2.3. Indicadores de Procesamiento en Segundo Plano

Varios de los módulos de análisis avanzado (como *Clustering*, Reglas de Asociación, Predicción y Anomalías) ejecutan algoritmos de aprendizaje automático que pueden requerir varios segundos de procesamiento. Para estos casos, el sistema presenta una barra de progreso con indicación del paso actual, como se muestra en la Ilustración 20.

A nivel de rendimiento, el entrenamiento de un modelo complejo —como un ensamble de *Random Forest* con validación cruzada sobre una muestra representativa— requiere aproximadamente entre 15 y 30 segundos, dependiendo de la capacidad de procesamiento del equipo *host*.




Ilustración 20: Indicador de progreso durante la ejecución de modelos de aprendizaje automático.

Una propiedad relevante de este mecanismo es que el usuario puede navegar a otra pestaña del *dashboard* mientras el cómputo se ejecuta en segundo plano. Al regresar a la pestaña original, los resultados se presentan de forma inmediata sin necesidad de re-ejecutar el algoritmo, siempre que los parámetros no hayan sido modificados.

A.2.4. Manejo de Errores y Límites Computacionales

Debido a la naturaleza intensiva de los algoritmos de *Spatial Data Mining*, el sistema cuenta con mecanismos de protección contra el agotamiento de memoria RAM (`MemoryError`). Si el usuario define configuraciones computacionalmente inviables —como aplicar el algoritmo FP-Growth con el soporte mínimo más bajo permitido por la interfaz (0,005) sobre la totalidad del corpus sin filtros temporales ni espaciales— el servidor interceptará el fallo para evitar la caída de la aplicación. En estos casos, la interfaz desplegará un mensaje de advertencia indicando que se ha excedido la capacidad de memoria disponible. La solución operativa ante este escenario consiste en reducir el volumen de datos mediante los filtros globales (seleccionando menos años o un solo *borough*) o ajustar los parámetros algorítmicos hacia valores más restrictivos (por ejemplo, aumentando el soporte mínimo a 0,01 o 0,02).

A.3. Módulo de Estadísticas Descriptivas

Este módulo comprende cuatro vistas orientadas a la exploración inicial del corpus de datos. Su propósito es brindar al analista un panorama general de la distribución criminal a través de conteos, proporciones y visualizaciones de distribución, sin recurrir a técnicas de aprendizaje automático.

A.3.1. Resumen General

La vista de Resumen General constituye la página de inicio del *dashboard* y ofrece una síntesis cuantitativa del conjunto de datos activo según los filtros aplicados (Ilustración 21). Se presentan cuatro indicadores clave de rendimiento (KPIs):

- **Total de registros:** cantidad total de denuncias en el subconjunto filtrado.
- **Felonies:** cantidad de delitos clasificados como graves (*felonies*).
- **Boroughs:** cantidad de distritos representados en los datos filtrados.
- **Período:** rango temporal cubierto por los datos (por ejemplo, “2020–2025”).

Debajo de los indicadores, se despliega una guía de navegación que describe brevemente el propósito de cada sección del *dashboard*, funcionando como un índice interactivo para el usuario.




Ilustración 21: Vista de Resumen General con los indicadores clave y la guía de navegación.

A.3.2. Análisis Temporal

La vista temporal provee tres visualizaciones complementarias para el estudio de patrones cronológicos en la actividad criminal:

1. **Evolución mensual por nivel de ofensa:** un gráfico de líneas que despliega la tendencia mes a mes, segregada por nivel de gravedad (*Felony*, *Misdemeanor*, *Violation*). El eje horizontal representa el tiempo y el eje vertical la cantidad de denuncias. Permite identificar estacionalidad y tendencias de largo plazo.
2. **Mapa de calor día de semana × hora:** una matriz visual donde las filas representan los días de la semana (lunes a domingo) y las columnas las horas del día (0 a 23). La intensidad del color indica la concentración de crímenes. Las celdas más oscuras revelan las combinaciones día/hora con mayor actividad delictiva (ver Ilustración 22).
3. **Comparación año contra año:** un gráfico de barras con el total anual de denuncias para cada año del período. Permite evaluar variaciones interanuales que podrían correlacionarse con políticas públicas o eventos extraordinarios.



Ilustración 22: Mapa de calor temporal: concentración de crímenes por día de semana y hora del día.

A.3.3. Análisis Geoespacial

Esta vista proyecta los datos sobre cartografía digital interactiva, ofreciendo dos elementos principales:

1. **Mapa de calor de densidad:** un *heatmap* superpuesto sobre el mapa base de la ciudad de Nueva York que muestra la concentración geográfica de los crímenes. Las zonas con

mayor densidad se representan con tonos cálidos (rojo intenso), mientras que las zonas con menor actividad se muestran en tonos fríos. Para garantizar un rendimiento fluido, el mapa muestrea hasta 50.000 puntos del conjunto de datos activo. Este muestreo utiliza una semilla aleatoria fija (seed=42), por lo que la visualización será idéntica en distintas sesiones para los mismos filtros.

2. **Distribución por borough:** un gráfico de barras que cuantifica la cantidad de crímenes registrados en cada distrito, ordenados de mayor a menor.

Adicionalmente, si se dispone de datos de infraestructura, el mapa superpone marcadores azules que representan la ubicación de las comisarías de policía. El control de capas, ubicado en la esquina superior derecha del mapa, permite activar o desactivar la visualización de cada capa de forma independiente (ver Ilustración 23).



Ilustración 23: Mapa de calor de densidad criminal con la capa de comisarías superpuesta.

A.3.4. Análisis Demográfico

La vista demográfica despliega el perfil estadístico de las víctimas y de los tipos de delito registrados. Se compone de tres bloques:

1. **Tipos de delito más frecuentes:** un gráfico de barras horizontales con los N tipos de crimen predominantes, donde N es ajustable mediante un deslizador interactivo (rango: 5

a 30). Permite identificar rápidamente los delitos con mayor incidencia en el subconjunto filtrado.

2. **Perfil de víctimas:** tres gráficos de torta que distribuyen las víctimas según grupo etario (<18, 18–24, 25–44, 45–64, 65+), sexo y raza. Los códigos internos del NYPD (por ejemplo, el código “D” para organizaciones comerciales en el campo de sexo) son traducidos automáticamente a etiquetas descriptivas, tal como se ilustra en la Ilustración 24.
3. **Tipo de premisa:** un gráfico de barras horizontales con los quince tipos de lugar más frecuentes donde ocurren los delitos (calle, residencia, comercio, entre otros).




Ilustración 24: Perfil demográfico de víctimas: distribución por grupo etario, sexo y raza.

A.4. Módulo de Análisis Avanzado

El módulo de análisis avanzado comprende seis vistas que implementan técnicas de *Spatial Data Mining*. A diferencia del módulo descriptivo, estas vistas incorporan parámetros configurables que el usuario puede ajustar para explorar distintas perspectivas analíticas. Los cálculos intensivos se ejecutan en segundo plano, permitiendo la navegación fluida durante el procesamiento.

A.4.1. Análisis Comparativo

Esta vista cruza los datos de criminalidad con las cuatro capas de infraestructura de referencia: las comisarías, las estaciones de bomberos y los establecimientos de salud del USGS, y las paradas de ómnibus de la MTA. Se compone de seis secciones, en este orden:

1. **Inventario de capas:** un indicador por capa con la cantidad de instalaciones cargadas, una tabla con esa cantidad y el número de distritos y de tipos de instalación de cada capa, y un gráfico de barras agrupadas con las instalaciones por *borough*. Las paradas de ómnibus no figuran en este gráfico porque la fuente no informa su distrito.
2. **Crímenes por comisaría:** un gráfico de barras y una tabla con el cociente entre los crímenes registrados en cada *borough* y la cantidad de comisarías del USGS ubicadas en él. Un cociente elevado indica una mayor carga de crímenes por comisaría en ese distrito.
3. **Exposición alrededor de las instalaciones:** el usuario ajusta un radio de análisis (100 m a 2,5 km, con 500 m por defecto) mediante un deslizador, y el sistema cuenta cuántos crímenes de una muestra de 15 000 ocurren dentro de ese radio alrededor de cada instalación de las cuatro capas. Una tabla resume, por capa, la media, la mediana y el máximo de crímenes en el radio, y un gráfico de barras horizontales muestra las veinte instalaciones con más crímenes, junto con el tipo de delito predominante en cada una.
4. **Capa más cercana a cada crimen:** para cada crimen de la misma muestra, el sistema identifica cuál de las cuatro capas tiene la instalación más próxima. Un gráfico de barras muestra cuántos crímenes quedan más cerca de cada capa, y otro los desagrega por nivel de ofensa.
5. **Mapa combinado:** un mapa interactivo que superpone el *heatmap* de una muestra de 15 000 crímenes con las instalaciones de cada capa: comisarías en azul, estaciones de bomberos en naranja, establecimientos de salud en rojo y paradas de ómnibus en verde. Al abrir la vista solo se muestran las comisarías; las demás capas se activan desde el control de capas, en la esquina superior derecha. Para no sobrecargar el navegador, cada capa dibuja como máximo 1500 instalaciones, de modo que las paradas de ómnibus se representan con una muestra (Ilustración 25).
6. **Nivel de ofensa por borough:** un gráfico de barras agrupadas que compara la cantidad de *felonies*, *misdemeanors* y *violations* en cada distrito.




Ilustración 25: Mapa combinado de la vista Comparativo V2: densidad criminal superpuesta con las comisarías, las estaciones de bomberos, los establecimientos de salud y las paradas de ómnibus.

A.4.2. Análisis de Proximidad

Esta vista permite investigar si los crímenes que ocurren cerca de una capa de equipamiento presentan características distintas a los que ocurren lejos. El usuario elige la capa de referencia y define el umbral de distancia que separa “cerca” de “lejos”. En la parte superior, cuatro indicadores resumen la muestra: el total de registros, la cantidad de crímenes de cada grupo y el porcentaje que queda del lado “CERCA”.

Controles interactivos.

- **Capa de referencia:** selector que define contra qué capa se miden las distancias: comisarías, estaciones de bomberos o establecimientos de salud del USGS, o paradas de ómnibus de la MTA. Por defecto, comisarías.
- **Umbral de distancia** (rango: 0,1 a 3,0 km): deslizador que define el punto de corte, con 0,5 km por defecto. Los crímenes a menos de esta distancia del elemento más cercano de la capa elegida se clasifican como “CERCA”; los demás como “LEJOS”.
- **Muestra** (rango: 5.000 a 50.000 registros): cantidad de registros sobre la que se calculan

las distribuciones de la vista, con 20.000 por defecto.

Visualizaciones principales.

1. **Distribución horaria (CERCA vs. LEJOS):** un par de diagramas de caja (*boxplots*) que compara la distribución de la hora del día en ambos grupos. Cada punto individual del conjunto de datos es visible (con transparencia y *jitter*). Debajo, una tabla resume cada grupo con la cantidad de registros, la media, la mediana, la desviación estándar, los cuartiles y el rango intercuartílico. Con la capa de comisarías, una diferencia en las medianas podría sugerir que la presencia policial disuade crímenes en ciertos horarios (ver Ilustración 26).
2. **Distancia por tipo de crimen (top 10):** *boxplots* que muestran la distribución de la distancia a la capa elegida para los diez tipos de delito más frecuentes de la muestra. Tipos con mediana elevada indican delitos que tienden a ocurrir lejos de esa capa.
3. **Matriz multicapa:** una tabla que informa, para cada una de las cuatro capas, la distancia media, la mediana, el percentil 75 y el porcentaje de crímenes que quedan por debajo del umbral, acompañada de un gráfico de barras con ese porcentaje. A diferencia de las dos visualizaciones anteriores, esta sección no depende de la capa elegida: calcula las distancias a las cuatro capas a la vez, con el mismo umbral.
4. **Proximidad por tipo de crimen:** una tabla con los veinte tipos de delito más frecuentes de la muestra que informa, para cada uno, la distancia media y el porcentaje de crímenes cercanos a cada una de las cuatro capas.
5. **Tabla cruzada entre capas:** un segundo selector (“Comparar contra”) elige otra capa, y la tabla distribuye los crímenes según su distancia a la capa de referencia y a la capa comparada, en cuatro franjas para cada una: menos de 250 m, de 250 a 500 m, de 500 m a 1 km y más de 1 km. Permite cuantificar cuántos crímenes quedan lejos de ambas capas a la vez.




Ilustración 26: Análisis de proximidad: distribución horaria de crímenes cerca y lejos de comisarías.

A.4.3. Clustering K-Means

Esta vista aplica el algoritmo de agrupamiento *K-Means* sobre las coordenadas geográficas de los crímenes para identificar automáticamente zonas de concentración delictiva (*hotspots*).

Controles interactivos.

- **Número de clusters (k):** deslizador que permite ajustar la cantidad de agrupamientos (rango: 3 a 20). Un valor bajo genera zonas amplias; un valor alto produce una segmentación más granular.

Resultados presentados.

1. **Mapa de clusters:** un mapa interactivo donde cada crimen se colorea según el *cluster* al que pertenece. Los centros de cada *cluster* se destacan con marcadores prominentes, y círculos de 1 km de radio delimitan la zona de influencia aproximada de cada agrupamiento. El usuario puede activar o desactivar cada *cluster* individualmente mediante el control de capas (Ilustración 27).
2. **Elbow Chart:** un gráfico de línea que muestra la inercia (suma de distancias al centro del *cluster*) para valores de k entre 2 y 15. El punto de inflexión o “codo” de la curva indica

el número óptimo de *clusters*. Una línea vertical roja señala el valor de k actualmente seleccionado (Ilustración 28).

3. **Tabla de centros:** las coordenadas exactas (latitud, longitud) de cada centro de *cluster* junto con la cantidad de crímenes asignados a cada uno, ordenados por tamaño descendente.




Ilustración 27: Mapa de clusters K-Means con centros y zonas de influencia ($k = 10$).




Ilustración 28: Método del codo (elbow chart) para la determinación del k óptimo.

A.4.4. Reglas de Asociación (FP-Growth)

Esta vista descubre patrones de coocurrencia entre tipos de delito y proximidad a infraestructura urbana mediante el algoritmo *FP-Growth*.

Controles interactivos. Los tres parámetros del algoritmo se exponen mediante deslizadores, y dos casillas de verificación permiten agregar dimensiones a las transacciones:

- **Soporte mínimo** (0,005 a 0,10, con 0,01 por defecto): la fracción mínima de transacciones que deben contener un conjunto de ítems para considerarlo frecuente. Valores bajos generan más reglas pero potencialmente menos significativas.
- **Confianza mínima** (0,5 a 1,0, con 0,70 por defecto): la probabilidad mínima de que el consecuente ocurra dado el antecedente. Valores altos filtran solo las reglas con mayor poder predictivo.
- **Umbral CERCA/LEJOS** (0,1 a 2,0 km, con 0,5 km por defecto): la distancia que separa un crimen “cercano” de uno “lejano” a la infraestructura.
- **Incluir dimensión temporal** (casilla, desactivada por defecto): agrega a cada transacción el bloque horario del incidente (HORA=MADRUGADA, HORA=MANANA, HORA=TARDE o HORA=NOCHE, que corresponden a las horas 0 a 5, 6 a 11, 12 a 17 y 18 a 23) y el tipo de día (DIA=ENTRE_SEMANA o DIA=FIN_DE_SEMANA, que comprende el sábado y el domingo).
- **Incluir nivel de gravedad** (casilla, desactivada por defecto): agrega a cada transacción el ítem NIVEL=FELONY, NIVEL=MISDEMEANOR o NIVEL=VIOLATION.

El algoritmo no se ejecuta sobre todos los registros filtrados: la página conserva los quince tipos de delito más frecuentes y toma de ellos una muestra aleatoria de hasta 10.000 incidentes, con semilla fija, cuya cantidad se informa debajo de los controles. Cada transacción contiene el tipo de delito (TIPO=) y, para cada capa de equipamiento, un ítem CERCA_ o LEJOS_ seguido del nombre de la capa: usgs_v2_policia, usgs_v2_bomberos, usgs_v2_salud o mta_omnibus. Las tablas de reglas de la sección 6.3.2 se obtuvieron con un umbral de 0,30 km y, en cada caso, con la casilla correspondiente activada.

Resultados presentados.

1. **Itemsets frecuentes:** los treinta conjuntos de ítems más frecuentes con su soporte.
2. **Reglas de asociación:** tabla con antecedente, consecuente, soporte, confianza y *lift*. Las reglas con *lift* superior a 1,5 se resaltan visualmente, indicando asociaciones más fuertes que lo esperado por azar (como se muestra en la Ilustración 29).

3. **KPIs**: cantidad total de reglas, cantidad de reglas con *lift* > 1,5 y confianza máxima encontrada.
4. **Gráfico de dispersión**: soporte vs. confianza para las cincuenta reglas principales, donde el tamaño y color de cada punto representan el *lift*.
5. **Descarga**: un botón exporta la tabla de reglas en formato CSV.
6. **Reglas espaciotemporales** (solo con la casilla temporal activada): la cantidad de reglas que contienen un ítem HORA= o DIA=, las treinta primeras ordenadas por *lift* y un gráfico de barras con las diez de mayor *lift*.
7. **Reglas por nivel de gravedad** (solo con la casilla de gravedad activada): la misma presentación para las reglas que contienen un ítem NIVEL=, junto con la cantidad de reglas de cada nivel entre las treinta mostradas y su *lift* promedio.

Ejemplo de lectura. Una regla del tipo [TIPO=ROBBERY] → [LEJOS_usgs_v2_policia] con confianza 0,85 se interpreta de la siguiente manera: el 85 % de los robos en la muestra analizada ocurren a una distancia superior al umbral definido respecto a la comisaría más cercana. Para saber si esa proporción es llamativa hay que mirar el *lift*: un valor cercano a 1 indica que la lejanía de las comisarías es igual de frecuente en el resto de los delitos de la muestra (sección 6.3.2.3).



V2: reglas de asociacion				
Reglas V2		Lift > 1.5	Confianza maxima	
900		21	1.000	
antecedent	consequent	support	confidence	lift
LEJOS_mta_omnibus	LEJOS_usgs_v2_bomberos, LEJOS_usgs_v2_policia	0.010000	1.000000	1.739400
LEJOS_mta_omnibus, LEJOS_usgs_v2_policia	LEJOS_usgs_v2_bomberos, LEJOS_usgs_v2_salud	0.010000	1.000000	1.650700
LEJOS_mta_omnibus	LEJOS_usgs_v2_bomberos, LEJOS_usgs_v2_salud	0.010000	1.000000	1.650700
LEJOS_mta_omnibus, LEJOS_usgs_v2_salud	LEJOS_usgs_v2_bomberos	0.010000	1.000000	1.527400
LEJOS_mta_omnibus, LEJOS_usgs_v2_policia	LEJOS_usgs_v2_bomberos	0.010000	1.000000	1.527400
LEJOS_mta_omnibus	LEJOS_usgs_v2_bomberos	0.010000	1.000000	1.527400
LEJOS_mta_omnibus, LEJOS_usgs_v2_policia, LEJOS_usgs_v2_salud	LEJOS_usgs_v2_bomberos	0.010000	1.000000	1.527400
TIPO=GRAND LARCENY OF MOTOR VEHICLE	LEJOS_usgs_v2_bomberos, LEJOS_usgs_v2_policia, LEJOS_usgs_v2_salud	0.021100	0.743000	1.401300
CERCA_mta_omnibus, TIPO=GRAND LARCENY OF MOTOR VEHICLE	LEJOS_usgs_v2_bomberos, LEJOS_usgs_v2_policia, LEJOS_usgs_v2_salud	0.020200	0.734500	1.385400
LEJOS_usgs_v2_salud, TIPO=GRAND LARCENY OF MOTOR VEHICLE	LEJOS_usgs_v2_bomberos, LEJOS_usgs_v2_policia	0.021100	0.793200	1.379800
TIPO=GRAND LARCENY OF MOTOR VEHICLE	LEJOS_usgs_v2_bomberos, LEJOS_usgs_v2_policia	0.022500	0.792300	1.378100

Filas resaltadas: lift > 1.5. Un lift mayor a 1 indica que la relacion aparece mas de lo esperado por azar.

Ilustración 29: Reglas de asociación descubiertas por FP-Growth, con resaltado de reglas con lift elevado.

A.4.5. Predicción ML

Esta vista entrena y evalúa dos modelos de clasificación para predecir el nivel de ofensa (*Felony*, *Misdemeanor* o *Violation*) a partir de variables temporales y geoespaciales.

Controles interactivos.

- **Árboles** (*n_estimators*, rango: 50 a 300): cantidad de árboles de decisión en el ensamble.
- **Profundidad máxima** (rango: 3 a 20): profundidad máxima de cada árbol.
- **Porcentaje de datos de test** (rango: 15 % a 40 %): proporción del conjunto de datos reservada para la evaluación final.
- **Modelo principal**: selector entre *Random Forest* y *Gradient Boosting*.

Resultados presentados.

1. **KPIs de rendimiento**: *accuracy* de ambos modelos, puntuación de validación cruzada (media $\pm$ desviación estándar) y cantidad total de *features* utilizadas.
2. **Validación cruzada**: gráfico de barras agrupadas con el *accuracy* de cada uno de los cinco *folds*, comparando ambos modelos lado a lado. Permite evaluar la estabilidad del rendimiento.
3. **Matriz de confusión**: un mapa de calor que muestra la distribución de predicciones correctas e incorrectas para cada clase. La diagonal principal contiene las clasificaciones acertadas (ver Ilustración 30).
4. **Reporte de clasificación**: tabla con *precision*, *recall* y F1 para cada clase.
5. **Importancia de features**: gráfico de barras horizontales con las quince *features* más influyentes en la predicción. Si las variables de distancia a infraestructura (*dist_usgs_v2_*

policia_km, dist_usgs_v2_bomberos_km y dist_usgs_v2_salud_km) aparecen entre las más importantes, se confirma la hipótesis de que la proximidad a infraestructura urbana es un factor relevante en la gravedad del delito.

6. **Interpretación automática:** el sistema genera un análisis textual indicando la posición en el ranking de importancia de cada una de las tres variables de distancia a la infraestructura del USGS.




Ilustración 30: Resultados del modelo de predicción: matriz de confusión e importancia de features usando random forest.

A.4.6. Detección de Anomalías

Esta vista identifica días con actividad criminal inusualmente alta o baja mediante el algoritmo *Isolation Forest*.

Controles interactivos.

- **Tasa de contaminación** (rango: 1 % a 15 %): la proporción esperada de observaciones anómalas en los datos. Un valor del 5 % implica que el algoritmo clasificará aproximadamente el 5 % de los días como anómalos.
- **Granularidad**: permite seleccionar entre analizar toda la ciudad en conjunto o segmentar por *borough*.

Resultados presentados.

1. **KPIs**: períodos totales analizados, cantidad de anomalías detectadas, porcentaje de anomalías y media de crímenes en los días anómalos.
2. **Timeline**: una serie temporal donde los días normales se representan como una línea azul continua y las anomalías como marcadores rojos en forma de cruz. Una línea horizontal punteada gris indica la media de los días normales, facilitando la comparación visual. Al posicionar el cursor sobre un marcador, se despliega información contextual (fecha, conteo de crímenes, *borough*), como se observa en la Ilustración 31.
3. **Tabla de top anomalías**: las veinte anomalías más extremas, ordenadas por su *score* de anomalía (valores más negativos indican mayor grado de atipicidad). Incluye fecha, conteo de crímenes, *borough* (si corresponde) y día de la semana.
4. **Distribución por borough**: gráfico de barras que muestra qué distritos concentran más días anómalos.
5. **Histograma de scores**: distribución del *anomaly score* del modelo, diferenciando visualmente las observaciones clasificadas como normales (azul) de las anómalas (rojo). La zona de transición entre ambos colores corresponde al umbral de decisión del algoritmo.



Ilustración 31: Serie temporal con anomalías detectadas por Isolation Forest. Los marcadores rojos señalan días con actividad criminal atípica.

A.5. Guía de Interpretación de Resultados

El propósito de esta sección es proveer al usuario de las herramientas conceptuales necesarias para interpretar correctamente los resultados producidos por el *dashboard*, evitando conclusiones erróneas derivadas de una lectura superficial de las métricas y visualizaciones.

A.5.1. Lectura de Métricas e Indicadores

En la Tabla 7 se describen las principales métricas utilizadas a lo largo del *dashboard*, junto con su interpretación y las precauciones que deben tomarse al momento de extraer conclusiones.

A.5.2. Consideraciones para el Análisis

Al utilizar los resultados producidos por la prueba de concepto, el investigador debe tener presentes las siguientes consideraciones:

- **Muestreo:** varias de las vistas analíticas operan sobre muestras del conjunto de datos completo para garantizar un rendimiento interactivo aceptable. Se aplica un muestreo aleatorio simple (*Simple Random Sampling*) preservando la distribución general de los datos. El tamaño de la muestra se indica en cada vista (por ejemplo, la vista geoespacial informa que el mapa de calor dibuja 50.000 de los 3.093.127 registros disponibles con los filtros pre-determinados). Los resultados deben interpretarse como estimaciones representativas, no como cómputos exhaustivos sobre la totalidad del corpus.

Métrica	Módulo	Interpretación y precauciones
Soporte	Reglas de Asociación	Proporción de transacciones que contienen el itemset. Un soporte de 0,05 indica que el patrón aparece en el 5 % de los casos. Valores muy bajos ($< 0,01$) pueden representar patrones estadísticamente débiles. (Para su fundamentación matemática, véase el capítulo 2).
Confianza	Reglas de Asociación	Probabilidad condicional: dado el antecedente, qué tan frecuente es el consecuente. Valores $> 0,8$ indican reglas fuertes. No implica causalidad.
Lift	Reglas de Asociación	Ratio entre la frecuencia observada y la esperada por independencia. Lift = 1 indica independencia; > 1 indica asociación positiva; < 1 indica asociación negativa.
Accuracy	Predicción ML	Proporción de predicciones correctas. Debe complementarse con la matriz de confusión, ya que un accuracy alto puede enmascarar un mal rendimiento en clases minoritarias.
F1	Predicción ML	Media armónica entre precision y recall. Útil cuando las clases están desbalanceadas, como es el caso de las violations frente a los felonies.
Inercia	Clustering	Suma de distancias al cuadrado de cada punto a su centro de cluster. Menor inercia implica clusters más compactos, pero siempre disminuye al aumentar k . El método del codo busca el punto de inflexión.
Anomaly Score	Anomalías	Valor que mide cuán atípica es una observación. Valores más negativos indican mayor atipicidad. No tiene unidad inherente; debe interpretarse en el contexto de la distribución de scores.

Tabla 7: Guía de interpretación de las principales métricas del dashboard.

- **Cobertura del filtro por borough:** el filtro global de *borough* descarta los registros cuyo distrito no está informado. Sobre el corte de datos utilizado en este trabajo (sección 6.3), esto representa 5.109 denuncias de un total de 3.098.236, de modo que las vistas analizan 3.093.127 registros. Se trata de una fracción menor al 0,2 %, pero conviene tenerla presente al contrastar los totales que muestra el *dashboard* con los que reporta el ETL al finalizar su ejecución.
- **Correlación y causalidad:** las asociaciones descubiertas por los módulos de reglas de asociación y proximidad indican patrones de coocurrencia estadística, pero no implican relaciones causales. La observación de que ciertos delitos ocurren lejos de comisarías no establece, por sí sola, que la ausencia de comisarías cause esos delitos.
- **Sesgo en los datos fuente:** los datos del NYPD representan denuncias formales registradas por la policía, no la totalidad de la actividad criminal. Delitos no denunciados no aparecen en el corpus. Asimismo, los criterios de clasificación del NYPD pueden haber variado a lo largo del período 2020–2025.
- **Reproducibilidad y actualización de datos:** dado que los algoritmos de aprendizaje automático utilizan semillas aleatorias fijas (`random_state=42`), los resultados analíticos son estrictamente reproducibles siempre que se mantengan los mismos datos de entrada y parámetros de configuración. No obstante, debe advertirse que el *pipeline* de extracción consulta en vivo dos fuentes del NYPD en NYC Open Data: el catálogo histórico (*Historic*, estático) y el endpoint del año en curso (*Current Year To Date*, recurso Socrata 5uac-w243). Este último es un recurso dinámico que el departamento policial actualiza trimestralmente e incluye reclasificaciones retrospectivas de denuncias recientes. Por tal motivo, volver a ejecutar la extracción ETL desde la API descargará registros adicionales o actualizados para el período reciente, lo que modificará levemente las cifras globales respecto a las documentadas en esta tesis. Para una replicación exacta y determinística de las métricas reportadas, se debe operar sobre los archivos Parquet procesados distribuidos en el repositorio. Asimismo, las capas de equipamiento institucional del USGS National Map se actualizan conforme al ciclo de publicación de dicho organismo federal.

A.6. Conclusión del Manual

Una vez comprendido el entorno operativo, la arquitectura de la interfaz y las consideraciones metodológicas descritas en este manual, se dispone del marco instrumental necesario para operar la prueba de concepto NYC Crime SDM Dashboard.